

DDTA - Scheda di lettura compilata

SRC-0024 - Wang et al. (2024) - Requirement-to-code traceability link recovery

Identita bibliografica

Campo	Valore
Titolo	An empirical study on the state-of-the-art methods for requirement-to-code traceability link recovery
Autori	Bangchao Wang; Zhiyuan Zou; Hongyan Wan; Yuanbang Li; Yang Deng; Xingfu Li
Sede	Journal of King Saud University - Computer and Information Sciences, 36(6), articolo 102118
DOI	10.1016/j.jksuci.2024.102118
Licenza	Open access - CC BY-NC-ND 4.0
Finestra empirica	Letteratura 2018-2023; 13 dataset Java; pubblicazione luglio 2024
Repository di replica	RCTLR_SOTA, riferimento 887c3a134d2892dcab103a1da399bdb4132ddaba

Validita temporale

Dimensione	Valutazione
Tipo di contributo	Selezione sistematica + benchmark empirico replicato
Sensibilita al tempo	Alta: ranking, modelli, dipendenze e capacita AI cambiano rapidamente
Stato temporale	Attuale come baseline 2024; non attuale come SOTA completa del 2026
Ancora applicabile	Disciplina del benchmark, confronto multi-progetto, class imbalance, threshold, metriche
Potenzialmente obsoleto	Ranking SOTA, toolchain, modelli pre-LLM; GPT e solo futuro lavoro
Uso consentito	Baseline pre-LLM/early-ML e protocollo di valutazione; non prova sulle prestazioni LLM

Cautela di riproducibilita: il repository pubblico contiene codice e risultati, ma il README richiede corpora, CoreNLP e alcuni dataset separati e rimanda altrove per TAROT e FTLR. Il pacchetto non e autosufficiente.

Domanda 1 - Problema e contributo

Il lavoro affronta la mancanza di benchmark uniformi per il recupero dei link requisito-codice e l'uso frequente di baseline tradizionali troppo deboli. Propone un framework in tre fasi: raccolta della letteratura, selezione di metodi riproducibili e valutazione sperimentale comune.

Il processo passa da 3609 record a 29 studi, valuta 11 candidati e seleziona sei lavori SOTA. La replica usa quattro famiglie IR e piu classificatori ML su 13 dataset Java.

Domanda 2 - Artefatti iniziali e rappresentazione

Gli input sono requisiti in linguaggio naturale, artefatti di codice Java e un insieme di link di riferimento. Ogni coppia requisito-codice e un candidato da ordinare o classificare. La fonte non deriva architettura, DFD o modello di sicurezza: valuta solo il recupero di link.

SRC-0024 - Metodo, risultati e limiti

Domanda 3 - Traceability, cambiamento, automazione e ruolo umano

I metodi combinano similarità testuale, parti del discorso, biterm condivisi, relazioni fine-grained, dipendenze tra artefatti e classificazione ML. Le metriche principali sono precision, recall e F1. Vengono variati threshold, rapporto training/test e bilanciamento SMOTE.

Il miglior metodo cambia tra dataset. Lo studio non misura direttamente tempo di revisione o fiducia dell'analista: precision e recall rappresentano solo indirettamente falsi positivi e omissioni.

Domanda 4 - Risultati, limiti e rapporto con DDTA

Non emerge un vincitore universale. Le tecniche IR e i modelli ML classici restano baseline credibili nel 2024. Sui dataset più grandi i migliori F1 sono spesso modesti. Per DDTA la fonte supporta il protocollo di valutazione, non dimostra qualità dei finding o superiorità degli LLM.

Metodo e corpus

Elemento	Dato
Banche dati	ACM DL, EI/Inspec, IEEE Xplore, ScienceDirect, SpringerLink, Web of Science + snowballing
Riduzione	3609 record -> 25 dopo screening -> 29 con snowballing -> 11 candidati -> 6 lavori SOTA
Dataset	16 idonei; 13 Java selezionati per gli esperimenti
IR	Conpos, TAROT, FTLR, CRT; VSM, LSI, LDA e Jensen-Shannon come basi
ML	Random forest, KNN, logistic regression, naive Bayes, SVM, hard-voting ensemble
Controlli	Rapporti training/test, SMOTE, threshold, top-N, Mann-Whitney U

Risultati quantitativi essenziali

Scenario	Risultato da usare con cautela
COEST - IR	Miglior F1 per progetto: 0.3406-0.5763; vincitore diverso per dataset
COEST - ML	Random forest + SMOTE guida i dataset ML; F1 0.3584-0.8146
Dataset grandi - IR	Miglior F1 0.0861-0.3814; Compos o TAROT secondo il progetto
Dataset grandi - ML	RF + SMOTE guida quasi tutti; F1 0.1551-0.3835; Maven voting 0.3099
Threshold	Cutoff spesso migliore di top-N; intervallo sperimentale proposto 0.05-0.14

Limiti dichiarati e aggiuntivi

Tipo	Limite
Autori	Soggettività nel filtro; preprocessing POS; errori su italiano; solo Java
Repliche	Alcuni metodi non eseguibili su tutti i dataset per limiti di codice/struttura
Temporale	Finestra 2018-2023; nessuna valutazione dei metodi RAG/LLM successivi
DDTA	Nessun documento-as-code, grafo di provenienza, finding o risultato di threat modeling
Riproducibilità	Repository utile ma non autosufficiente al riferimento verificato

SRC-0024 - Tabella di raccolta dati

Voce	Evidenza sintetica	Posizione	Tipo	Uso tesi
Problema	Benchmark non uniforme e baseline spesso deboli	p. 1-2	P	Cap. 3-4
Metodo	SLR + selezione qualita/evidenza + replica	p. 3-8	P	Cap. 3-4
Corpus	29 studi; 6 candidati; 13 dataset Java	p. 6-7	P	Cap. 4
Input	Requisiti, codice Java, ground truth dei link	p. 6-10	P	Cap. 2, 4
Metriche	Precision/recall 92.86%; F1 71.43% degli studi	p. 12	P	Cap. 4
COEST	Vincitore diverso; F1 best 0.3406-0.5763	p. 12-14	P	Cap. 3-4
Grandi dataset	F1 best IR 0.0861-0.3814; ML 0.1551-0.3835	p. 15-17	P	Cap. 3-4
Class imbalance	SMOTE cambia risultati; effetto dipende dal classificatore	p. 13-15	P	Cap. 4
Threshold	Cutoff sensibile; intervallo 0.05-0.14 derivato	p. 12-13	P/I	Cap. 4-5
Validita	Filtro soggettivo; italiano; solo Java	p. 17	P	Cap. 4, 8
Futuro	Few-shot, GPT, augmentation, tuning, industria	p. 18	P	Cap. 3
DDTA	Serve benchmark governato e multi-progetto	inferenza	I	Cap. 4-5

Registro delle evidenze candidate

ID	Proposizione	Stato
EX-0001	Manca un benchmark RC-TLR recente e uniforme	location_verified
EX-0002	La scelta di baseline condiziona la credibilita	location_verified
EX-0003	Selezione esplicita: 3609 -> 29 -> 11 -> 6; 13 Java	location_verified
EX-0004	Precision, recall e F1 sono metriche centrali	location_verified
EX-0005	Nessun vincitore IR indipendente dal progetto	location_verified
EX-0006	La politica di cutoff cambia la prestazione	location_verified
EX-0007	Bilanciamento e tuning cambiano il ranking ML	location_verified
EX-0008	Best-in-comparison non equivale a qualita operativa	location_verified
EX-0009	Generalizzazione limitata da lingua e Java	location_verified
EX-0010	GPT e futuro lavoro, non risultato sperimentale	location_verified

Legenda: C = citazione letterale; P = parafrasi fedele; I = interpretazione del ricercatore. Questa scheda usa parafrasi e interpretazioni separate; nessuna frase e una citazione letterale.

SRC-0024 - Sintesi DDTA e protocollo overlay

Abstract italiano (circa 150 parole)

Wang et al. costruiscono un benchmark empirico per il recupero automatico dei link tra requisiti e codice. Dopo una selezione della letteratura 2018-2023, replicano metodi IR e classificatori ML su 13 dataset Java. I risultati mostrano che non esiste un vincitore universale: metodo, threshold, bilanciamento e rapporto training/test cambiano le prestazioni. Random forest con SMOTE guida gran parte degli esperimenti ML, mentre CRT, TAROT, FTLR e Conpos prevalgono in progetti diversi. Sui dataset più grandi i valori F1 restano spesso modesti. La fonte è preziosa come baseline sperimentale 2024 e come monito contro confronti con baseline deboli. Non valuta però RAG o LLM moderni, non misura il costo della revisione umana e utilizza soltanto Java. Il repository di replica non è autosufficiente. Per DDTA, la fonte fonda un protocollo multi-progetto e riproducibile, ma non dimostra la validità dei link recuperati come evidenza di sicurezza.

Proposizioni direttamente supportate

- I risultati RC-TLR variano sostanzialmente tra dataset.
- La selezione delle baseline influenza la credibilità di un miglioramento.
- Precision, recall e F1 sono metriche centrali ma non sufficienti da sole.
- Class imbalance e threshold cambiano il comportamento dei metodi.
- IR e ML classici sono baseline necessarie per valutazioni successive.

Implicazioni candidate per DDTA e overlay

Controllo	Applicazione DDTA
Task separati	Distinguere estrazione, link candidato, relazione revisionata, finding e requisito
Baseline	Pin di implementazione, dipendenze, dataset e configurazione
Valutazione	Per-progetto + aggregata; threshold tuning separato dal test finale
Metriche	Precision, recall, F1 + tempo revisione + yield di candidati accettati
Generalizzazione	Progetti non visti, lingue e artefatti eterogenei
Governance	Ground truth, negativi, class balance e provenienza registrati
Output	Candidati ordinati con confidenza e stato di revisione, non link accettati

Cosa non possiamo sostenere

- Che il metodo migliore del 2024 sia ancora SOTA nel 2026.
- Che un LLM superi le baseline: la fonte non lo valuta.
- Che un link recuperato automaticamente sia una prova di sicurezza.
- Che un miglior F1 produca finding migliori o maggiore copertura delle minacce.
- Che i risultati Java generalizzino a tutti i linguaggi e progetti.

Prossima lettura

La fonte successiva dovrà misurare un metodo più moderno rispetto a questa baseline, con codice e testo integrale disponibili. La priorità è verificare classificazione fine-grained o pretrained language models prima di passare ai sistemi RAG/LLM generativi.