

DDTA - Scheda di lettura compilata

SRC-0025 - Hey, Keim e Corallo (2024) - Requirements classification for TLR

Identita bibliografica

Campo	Valore
Titolo	Requirements Classification for Traceability Link Recovery
Autori	Tobias Hey; Jan Keim; Sophie Corallo
Sede	IEEE 32nd International Requirements Engineering Conference (RE 2024), pp. 155-167
DOI	10.1109/RE59067.2024.00024
Accesso	Postprint open access KITopen
Metodo	NoRBERT + FTLR; due studi empirici
Materiale	Zenodo v2 + repository finegrained-traceability

Validita temporale

Dimensione	Valutazione
Tipo	Metodo peer-reviewed + dataset etichettato + due esperimenti
Sensibilita	Alta: modelli, baseline e capacita AI evolvono rapidamente
Stato	Attuale come evidenza BERT 2024; non come ranking AI completo del 2026
Ancora valido	Filtro task-specifico, holdout di progetto, class imbalance, error propagation
Potenzialmente obsoleto	Prestazioni BERT/fastText, traduzione, confronto pre-RAG/generative LLM
Uso tesi	Evidenza di miglioramento FTLR circoscritto; non prova per security analysis o LLM generativi

Cautela chiave: testo non funzionale o user-related puo essere irrilevante per il mapping funzionale al codice, ma puo contenere proprio l'evidenza necessaria a un'analisi di sicurezza.

Domanda 1 - Problema e contributo

Il lavoro verifica se la classificazione automatica dei frammenti di requisito puo rimuovere informazione non mappabile e ridurre i falsi positivi nel recupero requisito-codice. Integra NoRBERT come preprocessing di FTLR, crea un nuovo dataset etichettato e pubblica codice e risultati.

Domanda 2 - Artefatti e rappresentazione

Gli input sono requisiti e codice di eTour, iTrust, SMOS, eAnci e LibEST. I requisiti sono suddivisi in elementi e classificati come functional aspect, user-related, Function, Behavior e Data. Il nuovo subset contiene 447 requisiti e 3.284 elementi. Non viene derivato un modello architetturale, DFD o di sicurezza.

SRC-0025 - Metodo, risultati e limiti

Domanda 3 - Automazione e ruolo umano

NoBERT classifica i singoli elementi; FTLR può rimuovere elementi senza aspetti funzionali, elementi user-related o entrambi. La valutazione usa un holdout simile a leave-one-project-out. Il gold standard resta umano e i threshold ottimizzati per progetto richiedono link noti.

Il caso LibEST mostra il rischio di class imbalance: per la classe user-related il recall è 80%, ma la precision è soltanto 1,7%. Un filtro automatico può quindi produrre un forte carico di revisione o eliminare evidenza utile.

Domanda 4 - Risultati e rapporto con DDTA

Il filtro functional migliora modestamente FTLR: 34,5 -> 35,3% F1 con threshold originali e 37,8 -> 38,8% con threshold ottimizzati. La combinazione template + functional raggiunge 40,7%. Il filtro user-related riduce la prestazione media. Il miglior metodo continua a cambiare tra progetti.

Corpus e affidabilità dell'etichettatura

Voce	Dato
Progetti	eTour, iTrust, SMOS, eAnci, LibEST
Nuovo subset	447 requisiti; 3.284 elementi
Con PNFR	691 requisiti; 3.908 elementi
Annotatori	Un autore + uno studente magistrale; disaccordi risolti in discussione
Krippendorff alpha	0,742-0,905 secondo la classe
Lingua	SMOS/eAnci tradotti automaticamente in inglese
Valutazione	Holdout di progetto; BERTBASE/LARGE; 10/16 epoche; oversampling

Risultati quantitativi essenziali

Scenario	Risultato
Classificazione aggregata	Weighted F1 dichiarato: 84% per functional + user-related
Dettaglio best table	Functional circa 89,8%; user-related circa 81,8% weighted F1
Raro LibEST UR	Precision 1,7%; recall 80%; F1 circa 3,4%
Filtro F - ORG	Best average F1: 34,5 -> 35,3%
Filtro F - OPT	Best average F1: 37,8 -> 38,8%; Wilcoxon $p < 0,05$
Gold upper bound	F1 massimo 40,5%
UCT + F - OPT	F1 massimo 40,7%
Confronto selezionato	FTLR UCT+F: F1 37,1%; F2 40,6%; progetto-dipendente

Limiti

Tipo	Limite
Autori	Pochi progetti, molti accademici/studenti, dataset sbilanciati
Costrutto	Gold standard creato pensando all'approccio; traduzione automatica
Confronto	Threshold per progetto e link noti rappresentano un upper bound
DDTA	Nessuna security evidence, finding, review effort o stale-link maintenance
Temporalità	BERT 2024; nessun RAG o generative LLM moderno
Riproducibilità	Pacchetto strutturalmente auditato, non eseguito

SRC-0025 - Tabella di raccolta dati

Voce	Evidenza	Posizione	Tipo	Uso
Contributo	NoBERT filtra elementi prima di FTLR	p. 155-156	P	Cap. 3-5
Classi	F, UR, Function, Behavior, Data	p. 159	P	Cap. 3,5
Distinzione	Non-functional != privo di functional aspect	p. 159	P	Cap. 2,5
Corpus	447 req; 3.284 elementi; +PNFR 691/3.908	p. 160	P	Cap. 4
Gold	Alpha 0,742-0,905	p. 160	P	Cap. 4,8
Holdout	Un progetto non visto alla volta	p. 161	P	Cap. 4
Failure	LibEST UR: P 1,7%; R 80%	p. 162	P	Cap. 4,8
Filtro F	F1 37,8 -> 38,8% OPT	p. 163	P	Cap. 3-4
Combinazione	UCT+F raggiunge 40,7% F1	p. 164	P	Cap. 3-4
Confronto	Best medio, ma vincitore cambia per progetto	p. 164-165	P	Cap. 3-4
DDTA	Filtro deve essere specifico per overlay	inferenza	I	Cap. 5

Registro delle evidenze candidate

ID	Proposizione	Stato
EX-0001	Classificazione integrata prima del recovery	location_verified
EX-0002	Dataset + doppio esperimento	location_verified
EX-0003	Tre filtri F/UR/F+UR	location_verified
EX-0004	Non-functional e assenza di F non coincidono	location_verified
EX-0005	Corpus e inter-annotator agreement	location_verified
EX-0006	Holdout di progetto	location_verified
EX-0007	Rare-class failure LibEST	location_verified
EX-0008	Threats to validity	location_verified
EX-0009	Miglioramento FTLR modesto ma significativo	location_verified
EX-0010	UCT+F e confronto progetto-dipendente	location_verified
EX-0011	Generalizzazione e industria non dimostrate	location_verified

Legenda: C = citazione letterale; P = parafrasi fedele; I = interpretazione del ricercatore. La scheda non contiene citazioni letterali lunghe.

SRC-0025 - Sintesi DDTA e protocollo overlay

Abstract italiano

Hey, Keim e Corallo valutano la classificazione automatica dei frammenti di requisito come preprocessing per il recupero dei link requisito-codice. NoRBERT classifica aspetti funzionali, contenuto user-related e tre concern funzionali; FTLR usa i risultati per escludere frammenti ritenuti non mappabili. Il dataset comprende cinque progetti e una valutazione con progetto non visto. Il filtro functional migliora FTLR in modo modesto ma statisticamente significativo; la combinazione con regole di template raggiunge 40,7% F1. Il filtro user-related riduce invece la prestazione media. Il caso LibEST mostra che un buon risultato aggregato può nascondere una precision dell'1,7% su una classe rara. Lo studio è utile per governare preprocessing, class imbalance e upper bound, ma non valuta LLM generativi, industria, costo di revisione o sicurezza. Per DDTA, ogni filtro deve essere specifico dell'overlay e mantenere la provenienza del testo escluso.

Proposizioni direttamente supportate

- I frammenti di requisito hanno rilevanza diversa per uno specifico task di mapping.
- Gli errori del classificatore propagano nel recupero dei link.
- Il filtro functional può migliorare FTLR nel benchmark studiato.
- Il filtro user-related può danneggiare il recall.
- Holdout di progetto, class balance e threshold cambiano il risultato.

Implicazioni candidate per DDTA

Controllo	Applicazione
Semantica	Dichiarare perché un frammento è rilevante per quello specifico overlay
Provenienza	Conservare testo filtrato, regola, confidenza e decisione
Confidenze	Separare confidence del classifier e del trace candidate
Metriche	Per-classe + end-to-end; rare-class precision/recall obbligatorie
Threshold	Distinguere configurazione deployable e upper bound gold-optimized
Sicurezza	Mai trattare not-functional come not-security-relevant
Revisione	Human review su bassa confidenza o scarso supporto di classe

Cosa non possiamo sostenere

- Che NoRBERT o FTLR siano SOTA nel 2026.
- Che gli LLM generativi superino le baseline.
- Che l'esclusione di testo user-related o non funzionale sia valida per threat analysis.
- Che il miglioramento F1 riduca davvero il lavoro dei professionisti.
- Che il risultato generalizzi a progetti industriali o ad altri TLR.

Prossima lettura

SRC-0026 dovrà spostare il confronto su issue-to-commit recovery con un pretrained language model e multi-task learning, verificando cross-project behavior, class imbalance, ablation e completezza del pacchetto Zenodo.