

Scheda di lettura - SRC-0036

Garaccione, Calabrese, Coppola, Ardito (2025) - *A comparison of different Large Language Models for the generation of UML class diagrams*

Tipo	Ricerca primaria comparativa; MODELS-C 2025, pp. 541-545
DOI	10.1109/MODELS-C68889.2025.00078
Copia letta	IEEE Author's Accepted Manuscript, repository IRIS Politecnico di Torino
Hash PDF	7bdcc831571c7a1c0979bca8742c27020d637f034a98fb4bd339f015b625b019
Storage sorgente	Fuori dal repository Git; redistribuzione non autorizzata

1. Problema, obiettivo e contributo

Lo studio confronta quattro LLM nella generazione di diagrammi UML delle classi a partire da requisiti testuali universitari. Valuta separatamente validità sintattica, correttezza semantica e completezza rispetto a una soluzione di riferimento.

- **RQ1:** l'uso di LLM differenti produce differenze nella qualità dei diagrammi?
- **RQ2:** quali categorie di errore producono i diversi LLM?

Il contributo principale non è una classifica assoluta, ma la dimostrazione che i modelli presentano profili di forza e debolezza differenti e che nessuna singola metrica basta a qualificare un diagramma come corretto.

2. Disegno dello studio

Modelli	GPT-4o, DeepSeek v3, Gemini 2.5 Pro, Qwen 3
Accesso	Interfacce web gratuite; nessuna API
Corpus	15 esercizi universitari reali in italiano
Prompt	Role-based, few-shot, strutturato, identico per i quattro modelli
Output	JSON importabile in Apollon, editor web UML
Valutazione	Manuale: un autore, due revisioni indipendenti, consenso finale
Volume	4 modelli x 15 esercizi = 60 diagrammi (inferenza dal disegno)

3. Trasformazione studiata

requisiti naturali in italiano -> prompt role-based few-shot -> LLM via interfaccia web -> JSON Apollon -> diagramma UML delle classi candidato

Non esiste una rappresentazione intermedia governata che distingua elementi espliciti, inferenze, decisioni di modellazione, omissioni e aggiunte.

Regola centrale: JSON valido e diagramma renderizzabile non implicano fedeltà semantica alla fonte.

Risultati empirici e lettura delle figure

4. Metriche

- **Syntax Errors:** violazioni della notazione o delle regole UML adottate.
- **Semantic Errors:** tipo o direzione di associazioni, molteplicità, tipi di attributi/metodi, parametri e ritorni.
- **Completeness:** elementi generati corrispondenti al riferimento / elementi totali nel riferimento.

Gli errori semantici sono valutati solo sugli elementi già riconosciuti come corrispondenti; un'omissione riduce la completezza ma non necessariamente il conteggio semantico.

5. Statistiche descrittive

Modello	Sintassi	Semantica	Completezza
GPT-4o	0,00	4,33 (SD 2,44)	64,2% (31,8-100%)
DeepSeek v3	0,13 (SD 0,35)	3,00 (SD 1,60)	58,3% (24-100%)
Gemini 2.5 Pro	0,00	3,27 (SD 2,02)	67,7% (31,8-100%)
Qwen 3	3,20 (SD 1,70)	3,40 (SD 2,20)	55,4% (13,6-90,5%)

6. Lettura delle Figure 1 e 2

Figura 1 - distribuzioni

- La completezza di Gemini e ChatGPT è mediamente più alta, ma le distribuzioni si sovrappongono ampiamente.
- ChatGPT e Gemini collapsano a zero errori sintattici; DeepSeek è quasi sempre a zero; Qwen è nettamente peggiore.
- Le distribuzioni degli errori semantici si sovrappongono molto più di quelle sintattiche.

Conclusione visiva: la separazione netta fra modelli emerge quasi soltanto sulla sintassi di Qwen; la semantica resta un problema condiviso.

Figura 2 - categorie di errore

Categoria semantica	GPT	DeepSeek	Gemini	Qwen
methodAsAttribute	2	2	1	1
wrongAssociationOrder	2	2	3	2
wrongAssociationType	35	11	19	14
wrongAttributeType	2	2	3	1
wrongMethodInputParams	0	1	0	0
wrongMethodReturnType	4	4	4	3
wrongMultiplicity	20	24	19	29

- Qwen concentra quasi tutti gli errori sintattici: collectionAttribute, foreignKeyAttribute e unconnectedClass.
- ChatGPT domina wrongAssociationType; Qwen domina wrongMultiplicity.
- I due cluster semantici principali sono tipo di associazione e molteplicità.

Sintassi valida + copertura relativamente alta != modello semanticamente fedele e accettato.

Validita, discrepanze e limiti

7. Threats to validity dichiarate

Interna

- Valutazione iniziale di un solo autore, mitigata da due revisioni indipendenti e consenso finale.
- Il prompt potrebbe non essere ottimale; gli esempi few-shot possono introdurre overfitting.
- Prompt diversi avrebbero potuto favorire modelli differenti.

Costrutto

- Le metriche potrebbero non coprire tutte le dimensioni rilevanti.
- Le categorie di errore non sono necessariamente esaustive.
- La completezza come semplice rapporto di elementi e una misura riduttiva.

Esterna

- Non è dimostrata la generalizzazione ad altri formati di diagramma UML o ad altre notazioni.

8. Ulteriori limiti rilevanti per DDTA

- Corpus educativo italiano, non industriale e non mantenuto nel tempo.
- Diagrammi delle classi soltanto; nessun DFD, comportamento, deployment o threat model.
- Nessuna traceability fra singole asserzioni sorgente ed elementi UML.
- Nessuna gestione di cambiamento, versioni, staleness o rigenerazione.
- Nessuna ripetizione delle generazioni e nessuna misura della variabilità.
- Interfacce web dinamiche; snapshot, seed e parametri di decoding non disponibili.
- Nessuna misura del costo di correzione o del tasso di modelli accettati.
- La soluzione di riferimento e il matching per nome simile restano in parte soggettivi.

9. Discrepanze e ambiguità da preservare

- Il testo arrotonda ChatGPT e Gemini a circa 65%, ma la tabella riporta 64,2% e 67,7%.
- Il testo accosta DeepSeek e Qwen a circa 55%, ma la tabella riporta 58,3% e 55,4%.
- Le stime di completezza della Tabella III sono marcate con %, ma l'unità non è chiarita.
- La conclusione parla di un solo risultato significativo, mentre tre confronti pairwise contro Qwen sono significativi sulla sintassi.
- $p = 0,086$ è definito 'slightly significant' senza dichiarare una soglia alfa.
- La nozione conclusiva di 'overall correctness' non è definita come metrica composita.
- Refusi: DeepDeek, DeepSeel e grafie variabili di GPT-4o.

10. Validità temporale

Sensibilità alta. Il confronto fotografa modelli e interfacce del giugno 2025. Le classifiche non possono essere presentate come prestazioni correnti del 2026.

Elementi durevoli: separazione fra sintassi, completezza e semantica; dipendenza dal prompt; necessità di revisione umana; assenza di un vincitore universale.

Implicazioni per Documentation-Driven Threat Analysis

11. Pipeline DDTA derivata

documentazione governata -> contesto e provenance congelati -> candidato JSON/UML -> validazione schema -> validazione sintattica -> copertura della fonte -> validazione semantica -> validazione delle tracce -> review umana -> accettato | corretto | rifiutato | differito

12. Cosa la fonte supporta

- Gli LLM possono generare diagrammi UML delle classi parzialmente completi da requisiti naturali.
- I profili di errore cambiano fra modelli e fra metriche.
- La validità sintattica non garantisce correttezza semantica.
- Associazioni e molteplicità sono aree particolarmente problematiche.
- La revisione umana e la valutazione multidimensionale restano necessarie.
- Il modello scelto non sostituisce criteri di accettazione a livello di artefatto.

13. Cosa la fonte non supporta

- Generazione autonoma di un modello canonico e affidabile.
- Traceability completa fra requisiti e modello.
- Propagazione affidabile delle modifiche.
- Validità industriale o sicurezza/threat modeling.
- Sostituzione dei modellatori umani.
- Superiorità generale e attuale di uno dei quattro modelli.

14. Osservazioni del ricercatore

- **Il rischio principale sono le relazioni.** Ownership, dipendenze e confini possono essere distorti da associazioni o molteplicità errate.
- **La completezza può ingannare.** Un diagramma ricco di elementi può essere semanticamente peggiore di uno incompleto ma coerente.
- **Qwen fallisce prima; gli altri possono fallire dopo.** Qwen mostra problemi formali, mentre gli altri producono più spesso diagrammi plausibili ma concettualmente errati.
- **La governance deve essere artifact-centric.** Non si registra 'modello affidabile', ma evidenza di validazione per ogni candidato.

15. Relazione con SRC-0035

SRC-0035 mostra che un diagramma di sequenza chiaro e renderizzabile può non essere fedele ai requisiti. SRC-0036 mostra che un diagramma delle classi sintatticamente corretto e relativamente completo può contenere relazioni semanticamente errate.

Proiezione LLM candidata -> validazione specifica per la vista -> review umana -> modello accettato.

16. Stato della lettura

Testo	Completo, 6 pagine incluse copertina IRIS e articolo
Tabelle	Complete: Tabelle I-III
Figure	Verificate visivamente: Figure 1(a-b) e 2(a-b)
Didascalie e riferimenti	Completi
Esito	Scheda pronta per approvazione e drop-in

Nota di archiviazione: il PDF sorgente resta fuori dal repository. La futura raccolta stampabile offline dovrà essere costruita separatamente, ordinando per SRC-ID ogni articolo seguito dalla relativa scheda.