

Scheda di lettura - SRC-0038

Angermeir et al. (2026) - *Reflections on the Reproducibility of Commercial LLM Performance in Empirical Software Engineering Studies*

Tipo	Ricerca primaria empirica; ICSE 2026; critical review e reproduction study
DOI	10.1145/3744916.3773207
Copia letta	arXiv 2510.25506v3, 13 pagine, CC BY 4.0
File locale	SRC-0038-angermeir-amougou-kreitz-et-al-2026.pdf
SHA-256	a3dcd99af97693ae749c20ed8fd65f3e0551f98584a5b383643d16837f748745
Storage sorgente	Fuori dal repository Git per policy DDTA

1. Problema e contributo

Il paper verifica se studi software-engineering basati su LLM commerciali possano essere eseguiti e confermati da un gruppo indipendente. Il problema combina non determinismo, provider proprietari, aggiornamenti opachi, deprecazioni, prompt sensitivity e normali fragilita del software sperimentale.

- Analizza 85 studi LLM di ICSE 2024 e di un campione ASE 2024 filtrato sui badge.
- Individua 69 studi basati su servizi OpenAI e 18 apparentemente dotati di artefatti adatti.
- Solo cinque risultano sufficientemente completi ed eseguibili.
- Nessuno dei cinque viene riprodotto completamente; due sono parziali e tre divergono.

paper + repository pubblico + modello nominato != evidenza riproducibile

2. Ruolo conclusivo per DDTA

SRC-0038 aggiunge il confine temporale alle fonti SRC-0035-SRC-0037. Un candidato puo essere leggibile, semanticamente plausibile e perfino pubblicato con un artefatto, ma il risultato deve ancora conservare ambiente, input, modello, prompt, output grezzi, valutatore e stato di replay.

governed input -> execution specification -> raw outputs -> validation -> reported result -> optional independent rerun -> reproduced | partial | divergent | blocked | unavailable

Disegno dello studio e reproduction framework

3. Funnel di selezione

Passaggio	Conteggio	Nota
Studi LLM analizzati	85	78 ICSE + 7 ASE
Usano servizi OpenAI	69	Confine commerciale comune
Apparentemente riproducibili	18	Artefatti e dati sembrano disponibili
Effettivamente eseguibili	5	Tredici falliscono il gate di completezza/esecuzione

La branch ICSE deriva da una ricerca ampia su 425 articoli. La branch ASE è aggiunta iterativamente e mantiene solo sette studi con badge ACM. Il totale non è quindi un campione uniforme delle due venue.

4. Procedura di riproduzione

- Verifica di completezza di codice e dati.
- Prima esecuzione dell'artefatto e registrazione dei problemi.
- Interventi limitati che non dovrebbero cambiare la funzione sperimentale.
- Containerizzazione e automazione dei task.
- Code review indipendente dell'integrazione.
- Esecuzioni ripetute e conservazione delle osservazioni.

Gli artefatti originali vengono scaricati on demand. Le modifiche necessarie restano trasparenti, per separare il pacchetto originale dalla riparazione introdotta dal team di riproduzione.

5. Run count, costo e confronto

- Massimo 30 run per studio oppure stop a 500 USD.
- Il limite è pragmatico e non garantisce potenza statistica universale.
- Confronto descrittivo più Bayesian bootstrap con 10.000 draw e intervallo centrale del 95 per cento.
- Gli autori originali non vengono contattati, per testare l'autosufficienza del pacchetto.

original artifact != repaired reproduction environment

Risultati dei cinque studi eseguibili

6. Disposizione complessiva

Studio	Run / costo	Esito	Problema dominante
Pan et al. - code translation	15 / circa \$450	Non riprodotto	Versione GPT-4 non specificata; metriche molto inferiori
Ahmed et al. - summarization	30 / circa \$30	Non riprodotto	Modello deprecato, istruzioni e dipendenze incomplete
Siddiq et al. - regex/ReDoS	30 / circa \$30	Prevalentemente divergente	Evaluator incompleto e modello sostituito
Zhou et al. - vulnerability detection	30 / circa \$36	Parziale	Configurazioni bloccate e variabilit� fino a 10-30 punti
Xiao et al. - log parsing	30 / circa \$40	Parziale	Una metrica e parte del setup non disponibili

7. Esempi quantitativi

- **Code translation:** valori originali 79,9% e 85,5%; intervalli riprodotti circa 45,6-55,3% e 50,1-54,5%.
- **Regex/ReDoS:** cinque valori appaiono plausibili, 21 restano fuori dagli intervalli riprodotti.
- **Vulnerability detection:** alcuni risultati ricadono negli intervalli, ma la precisione di una configurazione varia dal 50% all'82,35%.
- **Log parsing:** 25 combinazioni su 32 ricadono negli intervalli osservati, ma il paper resta solo parzialmente riprodotto.

original value inside interval != stable operational behavior

8. Regola di granularit 

La disposizione deve poter essere assegnata al paper, al task, alla configurazione e alla singola metrica. Un risultato parzialmente riprodotto pu  contenere componenti confermate, divergenti e bloccate.

Reporting, blocker e badge

9. Informazioni disponibili negli 85 studi

Condizione	Conteggio
Nessun codice o dato condiviso	35
Artefatto irrecuperabilmente incompleto	15
Modello non identificato	8
Temperatura riportata	29
Top-p o top-k riportati	14
Context-window handling descritto	22
Prompt o template riportato	50

Il prompt è necessario ma non sufficiente. Servono anche modello esatto, context policy, input, preprocessing, evaluator, dipendenze, runtime, retries e output grezzi.

10. Fattori che impediscono la riproduzione

- Artefatti incompleti: 6 studi.
- Versioni delle dipendenze: 6.
- Problemi generali del codice: 5.
- Modelli deprecati: 5.
- Documentazione incompleta: 4.
- Artefatti non eseguibili: 2.
- Error handling insufficiente: 2.
- API esterna deprecata: 1.

Solo la deprecazione del modello e specifica dei provider commerciali. Tutti gli altri fattori sono normali problemi di manutenzione software e documentazione.

11. Badge ACM e validità temporale

Sedici studi hanno il badge Artifacts Evaluated - Reusable. Quattro artefatti risultano incompleti, tre non funzionano e uno non documenta abbastanza la riproduzione. Meta degli artefatti non soddisfa più lo stato atteso circa un anno dopo.

validation badge at T0 != executable artifact at T1

Discrepanze, limiti e interpretazione

12. Discrepanze preservate

- Il PDF usa coerentemente 85 studi (78 ICSE + 7 ASE); metadata esterni incontrati nel gate candidato riportavano 86.
- Il testo dice che Ahmed et al. non specificano la minor version, mentre Table 3 sembra marcarla come presente.
- Per Xiao et al. il testo dichiara due combinazioni vicine ma ne nomina tre, poi cinque improbabili ma ne elenca quattro.
- Reproducibility e replicability sono usati intenzionalmente in modo non sempre distinto.
- Il badge non è identificato come causa del fallimento: il paper osserva una mancata corrispondenza temporale.

13. Limiti

- Solo studi OpenAI entrano nello stage di riproduzione.
- Due venue e campione ASE filtrato sui badge.
- Cinque soli studi effettivamente eseguibili.
- Task, dataset e configurazioni spesso riprodotti in parte.
- Massimo 30 run e budget limitato.
- Sostituzioni di modello, dipendenze e codice indeboliscono l'equivalenza esatta.
- Nessun contatto con gli autori originali.
- Bootstrap limitato ai valori osservati.
- Artifact decay, provider drift e interventi del team non sono sempre separabili.

14. Cosa la fonte dimostra

- Disponibilità, completezza, executability e reproduction sono gate distinti.
- AI provenance e ordinary software provenance sono entrambe necessarie.
- Output grezzi e distribuzioni di run sono più informativi di un singolo punteggio.
- Originale e rerun devono avere identità e stati distinti.

15. Cosa non dimostra

- Che tutti gli studi LLM siano irriproducibili.
- Che 30 run siano sempre sufficienti.
- Che containerizzazione o modelli open garantiscano riproducibilità.
- Che un modello pinned sia realmente immutabile.

Contratto DDTA per execution provenance

16. Evidenza minima di un run LLM

Input	Target snapshot, source IDs, versioni e hash; inclusioni ed esclusioni.
Modello	Provider, famiglia, exact model ID/snapshot, endpoint e API version.
Prompt	System/user prompt, template version, sampling e tool parameters.
Context	Retrieval/index version, context-window e truncation policy.
Software	Pre/postprocessing, lockfile, runtime/container, evaluator e SBOM.
Esecuzione	Run count, timestamp, costo, errori, retries e stop condition.
Evidenza	Output grezzi, metriche, aggregazione, validation result.
Governance	Interventi umani, correction history, reviewer e disposition.
Replay	Original versus rerun; status e stale reason.

17. Lifecycle candidato

governed source snapshot -> run specification -> executable environment -> repeated runs -> raw outputs -> metric computation -> reported result -> optional independent rerun -> not_attempted | reproduced | partial | divergent | blocked | unavailable | superseded -> stale after input, model, prompt, dependency, evaluator or environment change

18. Relazione con SRC-0035-SRC-0037

Fonte	Gate aggiunto
SRC-0035	Leggibilità e sintassi non garantiscono fedeltà comportamentale.
SRC-0036	Struttura parser-valid non garantisce relazioni e molteplicità corrette.
SRC-0037	Correttezza apparente non garantisce coverage e grounding.
SRC-0038	Pubblicazione e artifact availability non garantiscono replay nel tempo.

ThreatForge, scope di tesi e chiusura corpus

19. Utilità concreta per ThreatForge

La fonte supporta un execution-provenance contract per estrazione assistita, generazione di modelli e future analisi LLM. Ogni run dovrebbe conservare input immutabile, model/prompt provenance, output candidato grezzo, validazioni, disposizione umana e stale reason. Un eventuale rerun deve essere una nuova evidenza collegata, non una sovrascrittura.

20. In scope per la tesi

- Provenance completa delle operazioni LLM implementate.
- Versioni e hash di input e candidati.
- Output grezzi separati dalle validazioni.
- Interventi umani e review disposition espliciti.
- Stato stale con trigger.
- Vocabolario future-compatible per il replay.

21. Out of scope per la tesi

- Framework universale per riprodurre studi scientifici esterni.
- Integrazione automatica Docker o Zenodo.
- Conservazione dei pesi commerciali.
- Garanzia di determinismo.
- Formula universale per il numero corretto di run.
- Validazione automatica dei badge ACM.
- Riesecuzione obbligatoria di ogni analisi durante la tesi.

execution provenance compatible with replay != implementation of a reproduction laboratory

22. Stato finale

Testo	Completo, 13/13 pagine
Figure	2/2 verificate
Tabelle	3/3 verificate
Riquadri RQ	3/3 verificati
Discrepanze	Registrate e non normalizzate
Companion artifacts	Identificati, non eseguiti
Corpus dopo acquisizione	21/21 letture centrali completate

La fonte chiude il corpus con evidenza empirica su provenance, temporal validity, artifact maintenance e independent rerun. Non viene usata per estendere lo scope implementativo oltre i controlli necessari a non impedire un replay futuro.